گزارش اعتبارسنجی مشتریان

پیش‌بینی نکول و اولویت‌بندی ریسک در دیتاست German Credit | ویژه‌ی مدیران ریسک و محصول

خلاصه‌ی مدیریتی

در این پروژه، مسئله از یک تصمیم اعتباری آغاز شد: چگونه می‌توان دسترسی به اعتبار را حفظ کرد و در عین حال، خطای پرهزینه‌ی تأیید متقاضیِ بدحساب را مهار کرد؟ برای پاسخ، داده‌ی تاریخی German Credit به یک فرایند امتیازدهی تبدیل شد؛ داده پس از کنترل کیفیت به آموزش و آزمون تفکیک شد، پیش‌پردازش در Pipeline و اعتبارسنجی متقاطع انجام گرفت و سه رویکرد از درخت تصمیم تا XGBoost و رگرسیون لجستیک مقایسه شدند.

در اجرای ثبت‌شده، XGBoost بهترین رتبه‌بندی آزمون را نشان داد (ROC-AUC برابر ۰٫۸۱۶) و در نقطه‌ی تصمیم منتخب، هزینه‌ی خطای آزمون از دو سیاست ساده‌ی «تأیید همه» و «رد همه» کمتر بود. پیام مدیریتی، با این حال، استقرار خودکار نیست: مدل در این مرحله نامزد یک ابزار پشتیبان تصمیم و triage برای بررسی انسانی است؛ نه مرجع نهایی پذیرش یا رد.

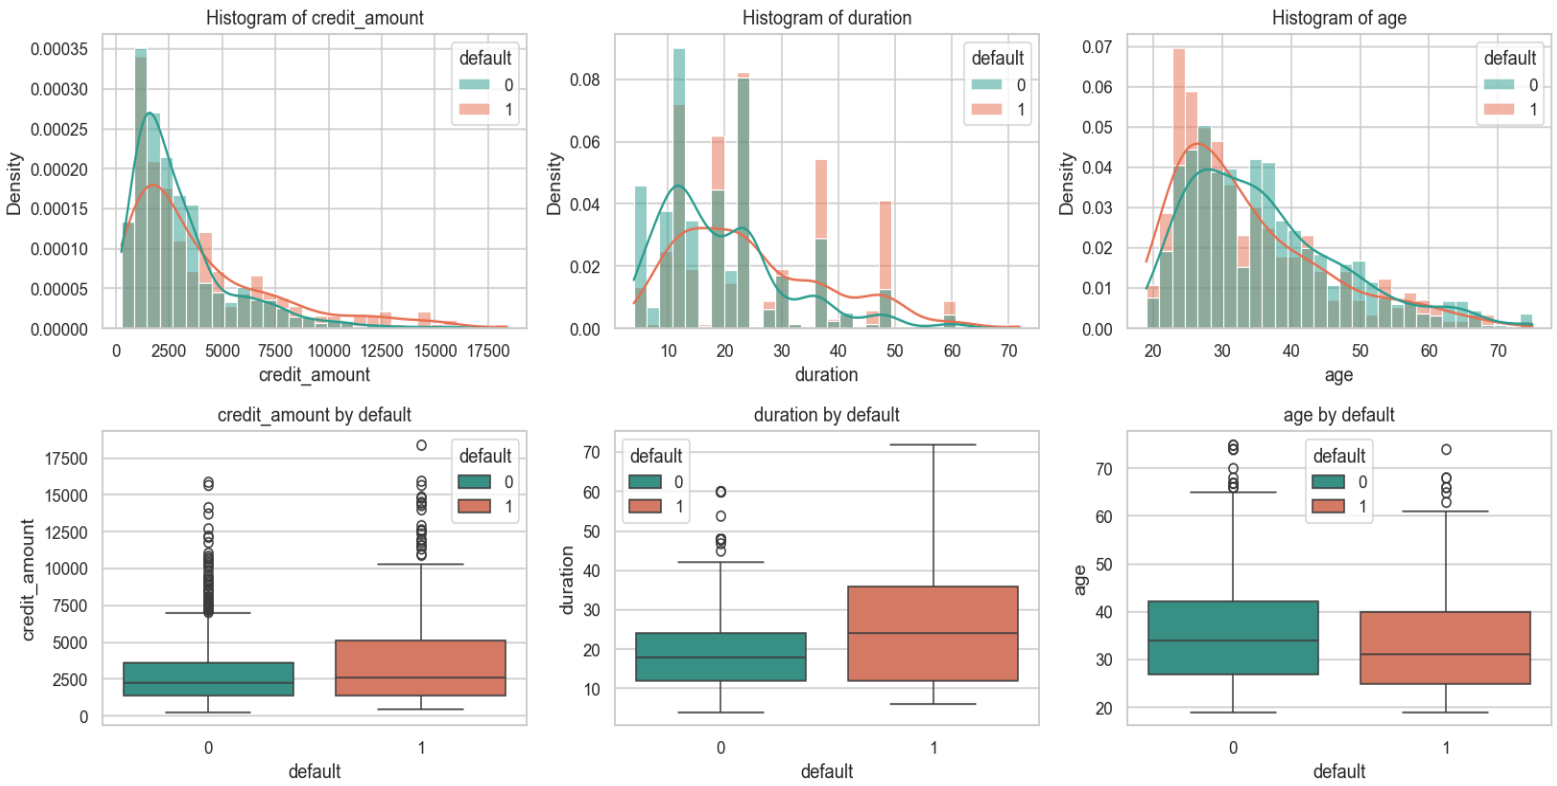
AUC آزمون	Cut-off منتخب	نرخ تأیید	نکول میان تأییدشدگان
۰٫۸۱۶	۰٫۱۸	٪۳۷	٪۸٫۱

این شاخص‌ها بر مبنای مجموعه‌ی آزمون و آستانه‌ی همان مدل گزارش شده‌اند؛ اعداد، عملکرد آتی یا نتیجه‌ی هر متقاضی را تضمین نمی‌کنند.

از پرونده تا داده

نمونه شامل ۱۰۰۰ پرونده‌ی تاریخی و ۲۰ ویژگی ورودی است؛ نسبت نکول حدود ۳۰٪ و نسبت کلاس بزرگ‌تر به کوچک‌تر ۲٫۳۳ به ۱ است. داده‌ی گمشده‌ی واقعی در فایل مشاهده نشد و سطح‌هایی مانند `unknown_none` به‌عنوان دسته‌های ثبت‌شده باقی ماندند. جداسازی طبقه‌بندی‌شده‌ی ۲۰/۸۰ پیش از برازش پیش‌پردازش انجام شد تا آزمون در انتخاب مدل دخالت نکند.

نمودار توزیع نشان می‌دهد مبلغ اعتبار راست‌چوله است و در مبلغ و مدت، مقادیر دور از بخش پرتراکم داده دیده می‌شود. این موارد به‌تنهایی خطای ثبت نیستند؛ دامنه‌ی تعمیم نیز محدود است: داده زمان درخواست را ندارد و فقط وام‌های پذیرفته‌شده را پوشش می‌دهد؛ بنابراین ارزیابی Out-of-Time و نتیجه‌گیری درباره‌ی تمام متقاضیان ممکن نیست.



شکل ۱. توزیع مبلغ اعتبار، مدت و سن به تفکیک برچسب نکول

از رتبه‌بندی تا نقطه‌ی تصمیم

Pipeline باعث شد Imputer، انکودر، مقیاس‌بندی مدل خطی و طبقه‌بند فقط در داده‌ی آموزشی هر Fold برازش شوند. اعتبارسنجی پنج‌تایی، XGBoost را با میانگین AUC برابر ۰٫۸۰۰ جلوتر از رگرسیون لجستیک (۰٫۷۸۱) و درخت تصمیم (۰٫۷۳۳) قرار داد؛ اما اختلاف XGBoost و مدل خطی محدود است و امتیازها بین Foldها تغییر می‌کنند. در آزمون نیز بازه‌های اطمینان AUC هم‌پوشانی دارند.

مقایسه‌ی عملکرد روی Test

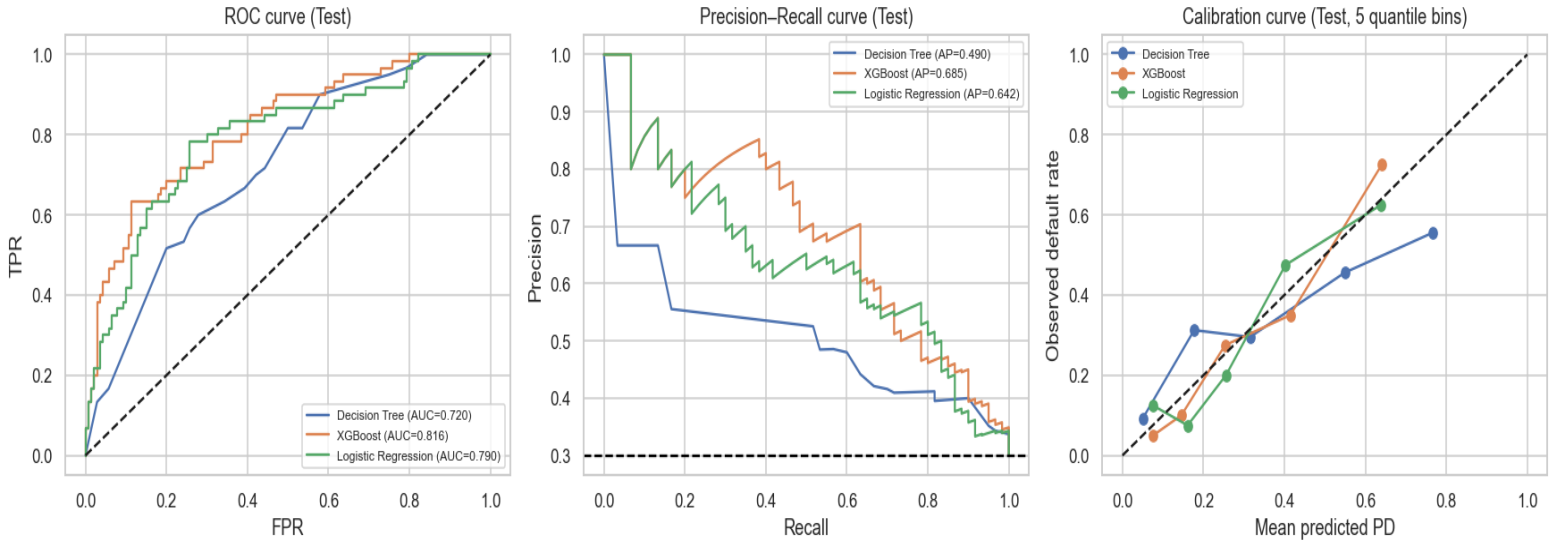
مدل	ROC-AUC	PR-AUC	Brier	Cut-off	هزینه
درخت تصمیم	۰٫۷۲۰	۰٫۴۹۰	۰٫۱۹۵	۰٫۱۱	۱۱۱
XGBoost	**۰٫۸۱۶**	**۰٫۶۸۵**	**۰٫۱۵۳**	**۰٫۱۸**	**۱۰۲**
رگرسیون لجستیک	۰٫۷۹۰	۰٫۶۴۲	۰٫۱۶۱	۰٫۱۸	۱۱۶

AUC رتبه‌بندی را می‌سنجد، PR-AUC را باید با توجه به نرخ پایه‌ی نکول خواند و Brier کیفیت احتمال‌های پیش‌بینی‌شده را خلاصه می‌کند.

هزینه و پیامد عملیاتی

هزینه‌ی خطای منفی کاذب (FN؛ تأیید بدحساب) در ماتریس پروژه پنج برابر خطای مثبت کاذب (FP؛ رد خوش‌حساب) فرض شده است. آستانه‌ی نظری ۰٫۱۶۷ فقط تحت فرض کالیبراسیون مناسب معنا دارد؛ برای XGBoost، Cut-off برابر ۰٫۱۸ از پیش‌بینی‌های OOF روی Train انتخاب و سپس روی Test ارزیابی شد.

در ۲۰۰ پرونده‌ی آزمون، XGBoost تأیید ۶ بدحساب از ۶۰ را از دست داد و ۷۲ خوش‌حساب را رد کرد؛ در نتیجه ۷۴ درخواست از ۲۰۰ درخواست تأیید شدند. هزینه‌ی محاسباتی آن ۱۰۲ واحد است، در برابر ۱۴۰ برای «رد همه» و ۳۰۰ برای «تأیید همه».

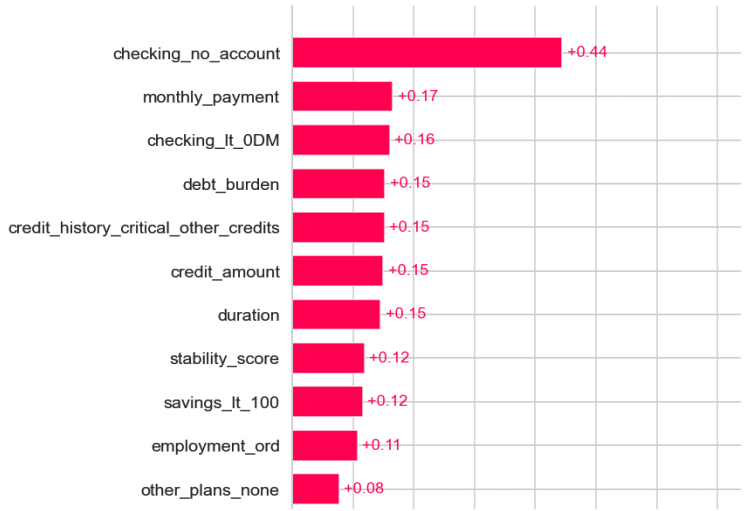


شکل ۲. منحنی‌های ROC، Precision–Recall و کالیبراسیون روی Test؛ نمودار کالیبراسیون مبتنی بر پنج بازه است و با نمونه‌ی آزمون کوچک باید محتاطانه خوانده شود.

هزینه‌ی OOF به‌ازای متقاضی برای XGBoost حدود ۰٫۵۱۲ است و اندکی از رگرسیون لجستیک پایین‌تر است؛ چون تنظیم ابرپارامترها و ارزیابی OOF از همین مجموعه‌ی آموزش استفاده کرده‌اند، برای برآورد بی‌طرفانه‌تر، Nested CV یا اعتبارسنجی زمانی با داده‌ی جدید مناسب‌تر است.

توضیح‌پذیری و مسیر استفاده‌ی مسئولانه

برای مدیر ریسک، امتیاز فقط زمانی مفید است که بتوان مسیر رسیدن از داده به تصمیم را بازبینی کرد. در تحلیل Global، `checking_no_account` بالاترین میانگین قدرمطلق SHAP را دارد؛ در نمونه‌ی محلی پرونده‌ی `debt_burden`، `B` بزرگ‌ترین سهم مثبت را در خروجی مدل داشته است. این تفاوت طبیعی است: یکی خلاصه‌ی اتکای مدل در کل Test است و دیگری توضیح یک پرونده‌ی مشخص.



خوانش نمودار

در میانگین |SHAP|، وضعیت حساب جاری از دیگر ویژگی‌ها برجسته‌تر است. در نمودار، سطح «بدون حساب جاری» با سهم‌های منفی مدل همراه شده، در حالی‌که «حساب جاری با موجودی منفی» برای بخشی از پرونده‌ها سهم مثبت دارد. سابقه‌ی اعتباری بحرانی نیز در این نمونه جهت ساده و شهودی ندارد؛ این الگوها برای بازبینی و پایش مهم‌اند، نه نسخه‌ی سیاستی مستقیم.

در پرونده‌ی B, PD پیش‌بینی‌شده ۸۶٫۲٪ و Cut-off برابر ۱۸٪ بود؛ واقعیت آزمون نیز نکول بود. سهم SHAP در Waterfall در مقیاس log-odds است، نه واحد درصد احتمال.

شکل ۳. میانگین قدرمطلق SHAP برای ویژگی‌های برجسته؛ اهمیت ویژگی، رتبه‌بندی اتکای مدل را نشان می‌دهد و جهت اثر باید جداگانه خوانده شود.

پیش از هر استفاده‌ی عملیاتی

یک نکته‌ی مدل‌سازی بر تفسیر اثرگذار است: `debt_burden` در کد برابر `duration × installment_rate / ۱۰۰` است؛ بنابراین شاخصی ترکیبی از مدت و طبقه‌ی نرخ قسط است، نه DTI یا نسبت واقعی اقساط به درآمد. `monthly_payment` نیز `credit_amount / duration` است و بهره و کارمزد را در نظر نمی‌گیرد.

ویژگی `personal_status_male_single` در میان ویژگی‌های برجسته‌ی SHAP دیده می‌شود. این مشاهده، ممیزی Fairness به تفکیک گروه را ضروری می‌کند؛ اما به‌تنهایی میزان تبعیض یا پیامد گروهی را اندازه‌گیری نمی‌کند. ویژگی‌های حساس نباید دلیل رد مشتری شوند و خروجی مدل نیازمند بازبینی انسانی است.

توصیه‌ی مدیریتی

مدل را در گام نخست در Shadow Mode یا پایلوت محدود به کار بگیرید: امتیاز مدل ثبت شود، اما تصمیم نهایی نزد کارشناس بماند. پیش از گسترش، عملکرد روی داده‌ی زمانی جدید، Calibration و خطاها به تفکیک گروه بررسی و Model Card تکمیل شود. پس از استقرار مجاز نیز Brier، AUC، نرخ‌های تصمیم و شاخص drift مانند PSI پایش شوند و برای افت عملکرد، مسیر توقف و بازبینی تعریف شود.

جمع‌بندی: XGBoost در این نمونه نامزد مناسب‌تری برای رتبه‌بندی اولیه است؛ ارزش مدیریتی آن در کمک به triage و تخصیص توجه کارشناسان است. تبدیل این نتیجه‌ی آزمایشی به سیاست اعتباردهی، به اعتبارسنجی مستقل، توضیح‌پذیری منضبط و کنترل‌های منصفانه وابسته است.

مبنای گزارش: خروجی ثبت‌شده‌ی `project_german_credit.ipynb`. تمامی هزینه‌ها واحدهای نسبی ماتریس خطای پروژه‌اند، نه مبالغ پولی.