تحلیل توزیع ویژگی‌ها و ریسک نکول اعتباری

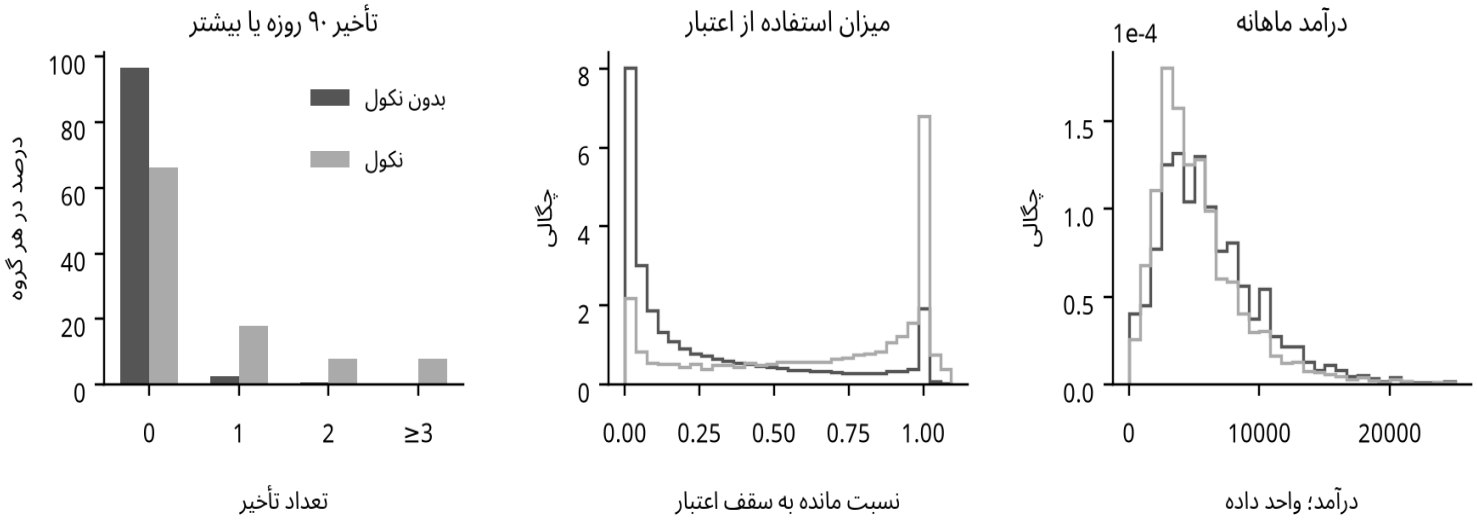
داده ارسالی شامل ۱۴۹٬۷۲۴ مشتری و ۱۴ ستون است؛ ۹٬۸۷۹ نفر (۶/۶۰٪) در گروه نکول قرار دارند. متغیر هدف SeriousDlqin است و تحلیل روی کپی داده انجام شده، فایل اصلی تغییر نکرده و مدل جدیدی آموزش داده نشده است.

بخش اول: تحلیل توزیع سه ویژگی

۱) تعداد تأخیرهای ۹۰ روزه یا بیشتر: توزیع صفرانبوه و راست‌چوله است؛ ۹۴/۶۱٪ مقادیر صفرند، مقدار گمشده ندارد و حداکثر ۱۷، کم‌فراوان و نیازمند بررسی است. وجود حداقل یک تأخیر در ۳۳/۶۶٪ گروه نکول، در برابر ۳/۳۹٪ گروه بدون نکول دیده می‌شود. نرخ نکول افراد دارای سابقه تأخیر ۴۱/۲۱٪ و برای سایر افراد ۴/۶۳٪ است؛ یعنی حدود ۸/۹ برابر. این تفاوت با ریسک بیشترِ بدحسابی گذشته سازگار است، اما این سابقه تنها یک‌سوم نکول‌ها را پوشش می‌دهد.

۲) **میزان استفاده از اعتبار:** توزیع به‌شدت راست‌چوله است و نزدیک صفر و یک تجمع دارد؛ میانه ۰/۱۵۳، میانگین ۵/۷۱۹ و حداکثر ۲۹٬۱۱۰ است. داده گمشده ندارد، ۷/۲۶٪ مقادیر صفرند و روش فاصله بین‌چارکی (IQR)، تعداد ۷۶۸ مورد (۰/۵۱٪) را پرت بالقوه نشان می‌دهد. میانه نسبت استفاده در گروه نکول ۰/۸۳۰ و در گروه بدون نکول ۰/۱۳۳ است؛ استفاده بالاتر می‌تواند نشانه فشار نقدینگی باشد. مقادیر بسیار بزرگ نیازمند اعتبارسنجی‌اند؛ بزرگ‌تر بودن از یک به‌تنهایی خطای ثبت را ثابت نمی‌کند.

۳) درآمد ماهانه: راست‌چوله است؛ میانگین ۶٬۶۵۰ از میانه ۵٬۴۰۰ بیشتر و حداکثر ۱٬۷۹۴٬۰۶۰ است. ۲۹٬۶۰۷ مقدار گمشده (۱۹/۷۷٪) و ۱٬۶۲۷ مقدار صفر (۱/۰۹٪ کل نمونه) وجود دارد؛ ۴/۰۶٪ درآمدهای ثبت‌شده نیز طبق IQR پرت بالقوه‌اند. در مشاهدات دارای درآمد، میانه گروه نکول ۴٬۵۰۰ و گروه بدون نکول ۵٬۴۷۰ است (۱۷/۷٪ کمتر)؛ این تفاوت با ظرفیت پرداخت پایین‌تر سازگار است، اما همپوشانی توزیع‌ها زیاد است. گمشدگی درآمد نیز بین دو گروه یکسان نیست؛ پس تعمیم این مقایسه به همه مشتریان احتیاط می‌خواهد.



نمودارها: خاکستری تیره = بدون نکول **روشن = نکول**

هر گروه جداگانه نرمال شده است. درآمد و استفاده از اعتبار فقط تا صدک ۹۹ نمایش داده شده‌اند؛ آمار متن از کل داده است. درآمدهای گمشده در محاسبات درآمد وارد نشده‌اند؛ واحد پول در فایل مشخص نیست.

پیشنهاد ساخت شاخص‌های ترکیبی:

نسبت تعهد مالی به درآمد DebtRatio همراه با MonthlyIncome بررسی و در صورت سازگاری تعریف ستون‌ها، یک سطح‌بندی از فشار بدهی بسازید؛ برای مثال، نسبت بدهی پایین، متوسط و بالا. این شاخص می‌تواند توان بازپرداخت را بهتر از درآمد یا بدهی به‌تنهایی بازتاب دهد. چون درآمد ماهانه حدود ۱۹٫۸٪ مقدار گمشده دارد و DebtRatio نیز مقادیر بسیار بزرگ دارد، گمشده‌ها را صفر فرض نکنید و مقادیر افراطی را پیش از تفسیر اعتبارسنجی کنید .

بخش دوم: بینش نهایی

برای شروع، تعداد تأخیرهای ۹۰ روزه یا بیشتر، میزان استفاده از اعتبار و درآمد ماهانه را انتخاب می‌کنم، زیرا به‌ترتیب سابقه بازپرداخت، فشار اعتباری و ظرفیت پرداخت را پوشش می‌دهند. تفاوت نرخ نکول و میانه‌ها از این انتخاب حمایت می‌کند، اما مدیریت مقادیر گمشده و پرت، و اطمینان از ثبت ویژگی‌ها پیش از رویداد هدف ضروری است. این یافته‌ها ارتباط آماری‌اند، نه اثبات علیت؛ ستون NumberOfDefault نیز به‌دلیل نشت اطلاعات در مجموعه منتخب قرار نمی‌گیرد.

تهیه شده توسط : مریم السادات صهبایی رضوی